

미팅 브리핑 평가 결과

계약관리 Agent 가 만드는 미팅 브리핑의 품질을 미팅 누적 깊이별로 평가했다.

- 케이스 30건 (고객사 체인 6 × 깊이 5)
- 전체 평균 89.8%
- 프롬프트 버전 contract_management.generate_briefing.v13
- 데이터셋·실행·채점 검사 2,545건 전부 통과

입력 규모

브리핑이 실제로 받는 확정 보고서와 같은 분량·구조로 만들었다.

항목	값
보고서	180건 (핵심 52 · 일상 기록 128)
핵심 보고서 평균	1,065자 (딜 본문 평균 909자)
일상 기록 평균	377자, 결정·요청·수치 없음
10회차 누적 입력	약 5,400자
30회차 누적 입력	약 16,900자

깊이별

미팅 누적	건수	평균	최저	필수 누락	부분 충족	해결건 재등장	중대 오류	RAG 미호출
1회 (첫 미팅)	6	95.1%	94.1%	0	0	0	0	0
3회	6	98.0%	88.2%	0	0	0	0	0
5회	6	95.8%	86.8%	0	1	0	0	0
10회	6	79.9%	52.9%	4	0	0	0	2
30회	6	80.4%	68.8%	2	5	3	0	1

10회차에서 크게 떨어진다. 1~5회차는 95~98% 지만 10회차 79.9%, 30회차 80.4% 다.

브리핑이 한 번에 읽는 보고서는 최신 3건뿐이고 그 나머지는 RAG 로만 닿는다. 10회차 이상에서 RAG 를 호출하지 않은 3건은 창 밖 미해결 이슈를 통째로 놓쳤다. 30회차에서는 이미 해결된 사안을 다시 올린 경우가 3건, 필수 주제를 부분적으로만 다룬 경우가 5건, 통째로 놓친 경우가 2건이다.

고객사 체인별

체인	건수	평균	최저	필수 누락	중대 오류
한빛병원 — 표준	5	95.2%	86.2%	1	0
청산네트웍스 — 전부 종결	5	93.6%	83.8%	0	0
한울제약 — 노이즈 극단	5	92.6%	75.0%	0	0
세종의료재단 — 딜 0건	5	92.6%	68.8%	0	0
대양산업 — 문서 충돌	5	83.0%	55.9%	2	0
미래로병원 — 값 변경 다수	5	82.0%	52.9%	3	0

값이 여러 번 바뀌는 체인(82.0%)과 보고서·문서 값이 어긋나는 체인(83.0%)이 가장 낮다.

코드로 확인한 것

검사	결과
존재하지 않는 근거 ID 인용	0건
근거 없어 필터에 삭제된 하이라이트	0건
필요한 RAG 호출 누락	3건
불필요한 RAG 호출	0건
중대 오류 (발언 왜곡·미합의를 합의로 등)	0건

근거를 지어내거나 고객 발언을 왜곡한 사례는 없다. 실패는 창 밖 과거 기록을 찾아 읽는가 와 이미 끝난 일을 접는가 에서 나온다.

대표 실패

RAG 미호출로 필수 주제 전부 누락 (miraero-d10 52.9%, daeyang-d10 55.9%)

두 건 모두 RAG 를 한 번도 호출하지 않았다. 미래로병원은 자동화 대상 검사 항목과 당시 장비 수량(20대)을, 대양산업은 설비 유지보수 종료 시점 미확인 건을 놓쳐 필수 주제 커버리지가 0 이다.

여러 미해결 이슈 중 일부만 반영 (daeyang-d30 70.8%)

좌석 수 충돌과 유지보수 요율 재협상은 부분적으로만 짚었고 구형 설비 연동 미검증 건은 놓쳤다. 이 케이스도 RAG 를 호출하지 않았다.

해결된 사안 재등장 (sejong-d30 68.8%, hanul-d30 75.0%)

이미 해소된 예산 편성 주기·결재 물량 미집계·전자결재 확장 취소 이슈를 다시 하이라이트로 올렸다.

채점 방식

항목	배점	누가
하이라이트 선택	25	코드 (주제별 판정에서 계산)
상태 추적	15	코드 (재등장·옛 값 사용)
사실 정확성	20	LLM
추천 행동	20	LLM
즉시성·가독성	10	LLM
부족한 정보	10	LLM

상태 변화가 없는 슬라이스는 상태 추적을 빼고 85점 만점으로 환산한다. 주제별 판정만 LLM 이 하고 점수 산술은 코드가 한다.

한계

- 합성 데이터이며 실제 고객 미팅이 아니다.
- 같은 케이스라도 LLM 응답은 매번 달라진다. 절대 점수보다 깊이별 경향을 본다.
- 참고자료(계약서·견적서·제품설명서) 자체의 품질은 자료요약 Agent 평가에서 따로 다룬다.